

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



[DATA VISUALIZATION USING D3.JS]

Giảng viên hướng dẫn:

Nguyễn Ngọc Minh Châu

THÔNG TIN NHÓM

<i>Mã nhóm</i>	<i>MSSV</i>	<i>Họ và tên</i>	<i>Ghi chú</i>
[22HTTT] [Nhóm 11]	22127107	Nguyễn Thế Hiển	Trưởng nhóm
	22127260	Bùi Công Mậu	
	22127355	Nguyễn Trần Đại Quốc	
	22127400	Thái Hữu Thọ	

LƯU Ý: CÁC VÍ DỤ CHỈ DÙNG ĐỂ MÔ TẢ CHO PHẦN TƯỞNG ỨNG, KHÔNG DÙNG ĐỂ CHỈ DẪN SV LÀM BÀI.

1. Dataprofiling

1.1 Tiền xử lí dữ liệu

Dữ liệu được cung cấp là file: project_heart_disease.csv.

```
project_heart_disease.csv X
project_heart_disease.csv > data
1 Age , Gender, Blood Pressure, Cholesterol Level, Exercise Habits, Smoking, Family Heart Disease, BMI , Alcohol Consumption, Stress L
2 56.0, Male , 153.0, 155.0, High , Yes , Yes , 24.991591091690363, High , Medium
3 69.0, Female, 146.0, 286.0, High , No , Yes , 25.2217985244363 , Medium , High
4 46.0, Male , 126.0, 216.0, Low , No , No , 29.85544714237164 , Low , Low
5 32.0, Female, 122.0, 293.0, High , Yes , Yes , 24.130476882852445, Low , High
6 60.0, Male , 166.0, 242.0, Low , Yes , Yes , 20.48628889057518 , Low , High
7 25.0, Male , 152.0, 257.0, Low , Yes , No , 28.14468145629605 , Low , Medium
8 78.0, Female, 121.0, 175.0, High , Yes , Yes , 18.042331891427416, Medium , Medium
9 38.0, Female, 161.0, 187.0, Low , Yes , Yes , 34.73668257227366 , Low , Medium
10 56.0, Female, 135.0, 291.0, Low , No , Yes , 34.49311222392957 , High , Low
11 75.0, Male , 144.0, 252.0, Low , Yes , Yes , 30.14214939745736 , Low , Medium
12 36.0, Female, 179.0, 191.0, High , No , Yes , 34.447617875399935, Medium , High
13 40.0, Female, 134.0, 296.0, High , No , Yes , 31.73962171282669 , , Medium
14 28.0, Female, 143.0, 215.0, High , Yes , No , 33.34401687767792 , Medium , Low
15 28.0, Female, 134.0, 191.0, High , Yes , No , 19.422428351469986, Low , Low
16 41.0, Female, 150.0, 187.0, High , No , Yes , 37.387840088014535, Medium , Low
17 70.0, Male , 133.0, 290.0, Medium , Yes , Yes , 32.166487733150326, Medium , Low
18 53.0, Female, 173.0, 255.0, Medium , No , Yes , 31.43387793501872 , Medium , Medium
19 57.0, Female, 133.0, 245.0, Low , No , Yes , 26.519301198402953, Medium , High
20 41.0, Male , 125.0, 219.0, Medium , Yes , Yes , 18.618979074613147, High , High
21 20.0, Female, 133.0, 187.0, High , Yes , No , 37.83215814436897 , , High
22 39.0, Female, 136.0, 246.0, High , Yes , Yes , 39.68463499193021 , Medium , High
23 70.0, Female, 137.0, 257.0, High , No , No , 35.77130616074112 , Low , Low
24 19.0, Female, 139.0, 268.0, Low , No , Yes , 38.13086159952928 , High , High
25 41.0, Female, 170.0, 300.0, Low , No , No , 20.661063756249103, , Low
26 61.0, Male , 136.0, 223.0, Low , Yes , No , 20.8308545388768 , High , High
27 47.0, Male , 135.0, 206.0, Low , No , No , 37.35133712851714 , Medium , High
28 55.0, Male , 159.0, 259.0, Low , Yes , No , 19.265130322915457, Low , High
29 19.0, Female, 158.0, 228.0, Low , Yes , Yes , 20.050477531320336, Low , High
30 77.0, Male , 171.0, 300.0, Medium , No , Yes , 35.970642888331675, High , High
31 38.0, Female, 151.0, 185.0, High , Yes , Yes , 30.253442705181836, Low , Low
32 50.0, Female, 179.0, 206.0, Medium , No , Yes , 26.617995615316403, Low , Medium
33 29.0, Female, 163.0, 278.0, Low , Yes , Yes , 30.175865561436687, , Medium
34 75.0, Male , 128.0, 152.0, High , Yes , No , 37.33244927306313 , Low , Low
35 39.0, Male , 146.0, 163.0, High , No , Yes , 34.65691078256311 , Low , High
36 78.0, Male , 165.0, 183.0, High , Yes , No , 33.215361505608676, High , Low
37 61.0, Female, 171.0, 219.0, Medium , No , Yes , 39.49148297993533 , High , Low
38 42.0, Male , 152.0, 218.0, High , Yes , No , 29.468748835065753, High , Medium
39 66.0, Female, 129.0, 253.0, Low , No , Yes , 18.139129637990113, , Low
```

File project_heart_disease.csv

Dữ liệu gồm 10000 bộ dữ liệu (không có header), có tổng cộng 11 thuộc tính được miêu tả như sau:

Thuộc tính	Miêu tả
Age	Tuổi
Gender	Giới tính (nam hoặc nữ)
Blood pressure	Huyết áp (tâm thu)
Cholesterol Level	Mức cholesterol toàn phần
Exercise Habits	Thói quen tập thể dục (thấp, vừa, cao)

Smoking	Có hút thuốc hay không (có hoặc không)
Family Heart Disease	Gia đình có tiền sử bệnh tim hay không (có hoặc không)
BMI	Chỉ số khối cơ thể
Alcohol Consumption	Mức tiêu thụ rượu
Stress Level	Mức độ căng thẳng
Heart Disease Status	Tình trạng bệnh tim (có hoặc không)

Dữ liệu được cho là dữ liệu thô, có khá nhiều dữ liệu có missing value:

```
Số lượng giá trị null:
Age                29
Gender             19
Blood Pressure     19
Cholesterol Level  30
Exercise Habits    25
Smoking            25
Family Heart Disease 21
BMI                22
Alcohol Consumption 2586
Stress Level       22
Heart Disease Status 0
dtype: int64
Số lượng giá trị missing values: 0
Số lượng dòng trùng lặp: 0
```

Dựa trên những thông tin trên, ta thực hiện quá trình tiền xử lý dữ liệu:

- + Đối với kiểu dữ liệu là dạng số (float), điền những ô trống bằng giá trị mean.
- + Đối với kiểu dữ liệu là dạng object, điền những ô trống bằng giá trị “Non” để nhận diện. Ở những trường hợp này, không thể điền giá trị cụ thể vào vì dễ làm sai lệch thông tin trong quá trình xử lý dữ liệu.

Sau quá trình tiền xử lý, ta thu được dữ liệu sạch vào file

“Preprocessing_project_heart_disease.csv”:

Preprocessing_project_heart_disease.csv

Preprocessing_project_heart_disease.csv > data

	Age	Gender	Blood Pressure	Cholesterol Level	Exercise Habits	Smoking	Family Heart Disease	BMI	Alcohol Co
1	56.0	Male	153.0	155.0	High	Yes	Yes	24.991591091690363	High
2	69.0	Female	146.0	286.0	High	No	Yes	25.2217985244363	Medium
3	46.0	Male	126.0	216.0	Low	No	No	29.85544714237164	Low
4	32.0	Female	122.0	293.0	High	Yes	Yes	24.130476882852445	Low
5	60.0	Male	166.0	242.0	Low	Yes	Yes	20.48628889057518	Low
6	25.0	Male	152.0	257.0	Low	Yes	No	28.14468145629605	Low
7	78.0	Female	121.0	175.0	High	Yes	Yes	18.042331891427416	Medium
8	38.0	Female	161.0	187.0	Low	Yes	Yes	34.73668257227366	Low
9	56.0	Female	135.0	291.0	Low	No	Yes	34.49311222392957	High
10	75.0	Male	144.0	252.0	Low	Yes	Yes	30.14214939745736	Low
11	36.0	Female	179.0	191.0	High	No	Yes	34.447617875399935	Medium
12	40.0	Female	134.0	296.0	High	No	Yes	31.73962171282669	Non
13	28.0	Female	143.0	215.0	High	Yes	No	33.34401687767792	Medium
14	28.0	Female	134.0	191.0	High	Yes	No	19.422428351469986	Low
15	41.0	Female	150.0	187.0	High	No	Yes	37.387840088014535	Medium
16	70.0	Male	133.0	290.0	Medium	Yes	Yes	32.166487733150326	Medium
17	53.0	Female	173.0	255.0	Medium	No	Yes	31.4338793501872	Medium
18	57.0	Female	133.0	245.0	Low	No	Yes	26.519301198402957	Medium
19	41.0	Male	125.0	219.0	Medium	Yes	Yes	18.618979074613147	High
20	20.0	Female	133.0	187.0	High	Yes	No	37.83215814436897	Non
21	39.0	Female	136.0	246.0	High	Yes	Yes	39.68463499193021	Medium
22	70.0	Female	137.0	257.0	High	No	No	35.77130616074112	Low
23	19.0	Female	139.0	268.0	Low	No	Yes	38.13086159952928	High
24	41.0	Female	170.0	300.0	Low	No	No	20.661063756249103	Non
25	61.0	Male	136.0	223.0	Low	Yes	No	20.8308545388768	High
26	47.0	Male	135.0	206.0	Low	No	No	37.35133712851714	Medium
27	55.0	Male	159.0	259.0	Low	Yes	No	19.265130322915457	Low
28	19.0	Female	158.0	228.0	Low	Yes	Yes	20.050477531320336	Low
29	77.0	Male	171.0	300.0	Medium	No	Yes	35.970642888331675	High
30	38.0	Female	151.0	185.0	High	Yes	Yes	30.25344270518184	Low
31	50.0	Female	179.0	206.0	Medium	No	Yes	26.617995615316403	Low
32	29.0	Female	163.0	278.0	Low	Yes	Yes	30.175865561436687	Non
33	75.0	Male	128.0	152.0	High	Yes	No	37.33244927306313	Low
34	39.0	Male	146.0	163.0	High	No	Yes	34.65691078256311	Low
35	78.0	Male	165.0	183.0	High	Yes	No	33.21536150560868	High
36	61.0	Female	171.0	219.0	Medium	No	Yes	39.49148297993533	High
37	42.0	Male	152.0	218.0	High	Yes	No	29.468748835065757	High
38	66.0	Female	129.0	253.0	Low	No	Yes	18.139129637990116	Non

File Preprocessing_project_heart_disease.csv

1.2 Profiling toàn bộ dữ liệu

Tiến hành profiling toàn bộ dữ liệu thu được kết quả như sau:

	Field Name	NULL	Missing	Actual	Completeness (%)	Cardinality	Uniqueness (%)	Distinctness (%)
0	Age	0	0	10000	100.0	64	0.64	0.64
1	Gender	0	0	10000	100.0	3	0.03	0.03
2	Blood Pressure	0	0	10000	100.0	62	0.62	0.62
3	Cholesterol Level	0	0	10000	100.0	152	1.52	1.52
4	Exercise Habits	0	0	10000	100.0	4	0.04	0.04
5	Smoking	0	0	10000	100.0	3	0.03	0.03
6	Family Heart Disease	0	0	10000	100.0	3	0.03	0.03
7	BMI	0	0	10000	100.0	9979	99.79	99.79
8	Alcohol Consumption	0	0	10000	100.0	4	0.04	0.04
9	Stress Level	0	0	10000	100.0	4	0.04	0.04
10	Heart Disease Status	0	0	10000	100.0	2	0.02	0.02

Nhận xét:

- Sau khi preprocessing dữ liệu, thì đã xử lý được hết các giá trị NULL nên toàn bộ là 0.

- Chỉ có duy nhất Heart Disease Status là có đầy đủ những thông tin cơ bản Completeness là 100%. Các thuộc tính còn lại đều có chỉ số Completeness trên 99% (trừ Alcohol Consumption với 74.14%), tùy theo dữ liệu mà xử lý missing values.
- Gender, Exercise Habits, Smoking, Family Heart Disease, Alcohol Consumption, Stress Level, Heart Disease Status có giá trị Uniqueness, Distinctness thấp điều này dễ hiểu do chúng có giá trị từ 2-4 giá trị.
- BMI có giá trị Cardinality, Uniqueness và Distinctness cao điều này cho thấy gần như mỗi dòng có giá trị khác nhau và duy nhất.
- Chưa xác định được khóa chính cho tập dữ liệu. Mặc dù thuộc tính BMI có Distinctness 100%, nhưng có thể có sự trùng lặp trong dữ liệu thực tế.

1.3 Profiling từng thuộc tính

Age:

Metadata			Age Popular			Age Field Data Types		
Attribute	Field Datatype	Field Length	Value	Count	Percentage (%)	Data Type	Count	Percentage (%)
Age	float64	1	18	149	1.49	float64	10000	100
			19	155	1.55	NULL	0	0
Data Profiling Summary			20	154	1.54			
Attribute	Value		21	162	1.62			
NULL	0		22	142	1.42			
Missing	0		23	160	1.6			
Actual	10000		24	132	1.32			
Completeness (%)	100		25	168	1.68			
Cardinality	64		26	147	1.47			
Uniqueness (%)	0.64		27	142	1.42			
Distinctness (%)	0.64		28	157	1.57			
			29	156	1.56			
Data Profiling Additional Statistics			30	161	1.61			
Attribute	Value		31	152	1.52			
Data Types	1		32	160	1.6			
Field Length (MIN)	2		33	149	1.49			
Field Length (MAX)	2		34	182	1.82			
Field Value (MIN)	18		35	157	1.57			
Field Value (MAX)	80		36	156	1.56			
Mean	49.3		37	161	1.61			
Median	49		38	168	1.68			
Standard Deviation	18.17		39	169	1.69			
			40	174	1.74			
			41	154	1.54			
			42	167	1.67			
			43	163	1.63			

Tổng quát:

Độ hoàn chỉnh (Completeness)

- Thuộc tính Age có độ hoàn chỉnh 100%, không có giá trị NULL.
- Dữ liệu đầy đủ, không cần xử lý thiếu dữ liệu.

Cardinality (Số lượng giá trị duy nhất)

- Có 64 giá trị duy nhất, tức là có 64 mức tuổi khác nhau.
- Điều này cho thấy dữ liệu phân bố đa dạng, không bị nhóm lại thành quá ít mức.

Uniqueness & Distinctness

- Uniqueness: 0.64% → Điều này có nghĩa là mỗi giá trị tuổi xuất hiện nhiều lần trong tập dữ liệu.
- Distinctness: 0.64% → Dữ liệu có sự lặp lại khá nhiều giữa các mức tuổi.

Nhận xét chi tiết

Phân phối độ tuổi

- Dữ liệu về độ tuổi dao động từ 18 đến 80 tuổi.
- Độ tuổi phổ biến (có nhiều người nhất) nằm trong khoảng 30-50 tuổi với tỷ lệ từ 1.5% - 1.8% mỗi mức tuổi.
- Không có outlier bất thường, dữ liệu phân bố đều.

Thống kê số liệu

- Giá trị nhỏ nhất (Min): 18 tuổi.
- Giá trị lớn nhất (Max): 80 tuổi.
- Trung bình (Mean): 49.3 tuổi.
- Trung vị (Median): 49 tuổi → Dữ liệu khá đối xứng.
- Độ lệch chuẩn (Standard Deviation): 18.17 → Độ tuổi khá phân tán, không tập trung chặt vào một khoảng cố định.

Dữ liệu dạng số (Numeric)

- Toàn bộ dữ liệu trong Age là kiểu float64.
- Không có giá trị NULL (tỷ lệ 0%).
- Không cần xử lý kiểu dữ liệu, hoàn toàn phù hợp để phân tích số.

Gender:

- Số lượng Female (Nữ giới): 4978 (chiếm 49.78% tổng dữ liệu).
- Tỷ lệ giới tính khá cân bằng, không có sự chênh lệch đáng kể giữa hai nhóm.

Thống kê số liệu

- Dữ liệu kiểu object (chuỗi ký tự), không phải số.
- Chiều dài chuỗi ký tự dao động từ 4 đến 6 ký tự (Male có 4 ký tự, Female có 6 ký tự).
- Không có giá trị NULL (tỷ lệ 0%).
- Dữ liệu được chuẩn hóa tốt, không có lỗi định dạng.

Blood Pressure:

Metadata			Blood Pressure Popular			Blood Pressure Field Data Types		
Attribute	Field Datatype	Field Length	Value	Count	Percentage (%)	Data Type	Count	Percentage (%)
Blood Pressure	float64	1	120	174	1.74	float64	10000	100
Data Profiling Summary			121	162	1.62	NULL	0	0
			122	161	1.61			
			123	161	1.61			
			124	169	1.69			
			125	148	1.48			
			126	178	1.78			
			127	169	1.69			
			128	171	1.71			
			129	177	1.77			
			130	136	1.36			
Data Profiling Additional Statistics			131	140	1.4			
			132	172	1.72			
			133	178	1.78			
			134	214	2.14			
			135	148	1.48			
			136	177	1.77			
			137	175	1.75			
			138	171	1.71			
			139	157	1.57			
			140	181	1.81			
Standard Deviation	17.56		141	159	1.59			
			142	181	1.81			
			143	165	1.65			
			144	156	1.56			
			145	168	1.68			

Tổng quát

Độ hoàn chỉnh (Completeness)

- Thuộc tính Blood Pressure có độ hoàn chỉnh 100%, không có giá trị NULL.
- Dữ liệu đầy đủ, không cần xử lý thiếu dữ liệu.

Cardinality (Số lượng giá trị duy nhất)

- Có 62 giá trị duy nhất, tức là có 62 mức huyết áp khác nhau.

- Điều này cho thấy dữ liệu phân bố đa dạng, không bị gom cụm vào quá ít mức.

Uniqueness & Distinctness

- Uniqueness: 0.62% → Mỗi mức huyết áp xuất hiện nhiều lần trong tập dữ liệu.
- Distinctness: 0.62% → Dữ liệu có sự lặp lại đáng kể giữa các mức huyết áp.

Nhận xét

Phân phối huyết áp

- Dữ liệu về huyết áp dao động từ 120 đến 180 mmHg.
- Mức huyết áp phổ biến nhất nằm trong khoảng 125-150 mmHg, với tỷ lệ dao động từ 1.5% - 1.8% mỗi mức huyết áp.
- Không có outlier bất thường, dữ liệu phân bố khá đều.

Thống kê số liệu

- Giá trị nhỏ nhất (Min): 120 mmHg.
- Giá trị lớn nhất (Max): 180 mmHg.
- Trung bình (Mean): 149.76 mmHg.
- Trung vị (Median): 150 mmHg → Dữ liệu khá đối xứng.
- Độ lệch chuẩn (Standard Deviation): 17.56 → Huyết áp phân tán đáng kể, không tập trung vào một khoảng cố định.

Dữ liệu dạng số (Numeric)

- Toàn bộ dữ liệu trong Blood Pressure là kiểu float64.
- Không có giá trị NULL (tỷ lệ 0%).
- Không cần xử lý kiểu dữ liệu, hoàn toàn phù hợp để phân tích số.

Cholesterol Level:

Metadata			Cholesterol Level Popular			Cholesterol Level Field Data Types		
Attribute	Field Datatype	Field Length	Value	Count	Percentage (%)	Data Type	Count	Percentage (%)
Cholesterol Level	float64	1	150	61	0.61	float64	10000	100
			151	57	0.57	NULL	0	0
			152	72	0.72			
Data Profiling Summary			153	62	0.62			
Attribute	Value		154	65	0.65			
NULL	0		155	66	0.66			
Missing	0		156	62	0.62			
Actual	10000		157	49	0.49			
Completeness (%)	100		158	61	0.61			
Cardinality	152		159	66	0.66			
Uniqueness (%)	1.52		160	64	0.64			
Distinctness (%)	1.52		161	67	0.67			
Data Profiling Additional Statistics			162	78	0.78			
Attribute	Value		163	65	0.65			
Data Types	1		164	56	0.56			
Field Length (MIN)	3		165	78	0.78			
Field Length (MAX)	3		166	77	0.77			
Field Value (MIN)	150		167	75	0.75			
Field Value (MAX)	300		168	69	0.69			
Mean	225.43		169	47	0.47			
Median	225.43		170	65	0.65			
Standard Deviation	43.51		171	63	0.63			
			172	67	0.67			
			173	63	0.63			
			174	61	0.61			

Tổng quát

Độ hoàn chỉnh (Completeness)

- Thuộc tính Cholesterol Level có độ hoàn chỉnh 100%, không có giá trị NULL.
- Dữ liệu đầy đủ, không cần xử lý thiếu dữ liệu.

Cardinality (Số lượng giá trị duy nhất)

- Có 152 giá trị duy nhất, tức là có 152 mức cholesterol khác nhau.
- Điều này cho thấy dữ liệu có sự phân bố rất đa dạng, không bị gom cụm vào ít mức.

Uniqueness & Distinctness

- Uniqueness: 1.52% → Mỗi mức cholesterol xuất hiện nhiều lần trong tập dữ liệu.
- Distinctness: 1.52% → Dữ liệu có sự lặp lại đáng kể giữa các mức cholesterol.

Nhận xét

Phân phối mức cholesterol

- Dữ liệu về mức cholesterol dao động từ 150 đến 300 mg/dL.

- Mức cholesterol phổ biến nhất nằm trong khoảng 180-250 mg/dL, với tỷ lệ dao động từ 0.5% - 0.8% mỗi mức cholesterol.
- Không có outlier bất thường, dữ liệu phân bố khá đồng đều.

Thống kê số liệu

- Giá trị nhỏ nhất (Min): 150 mg/dL.
- Giá trị lớn nhất (Max): 300 mg/dL.
- Trung bình (Mean): 225.43 mg/dL.
- Trung vị (Median): 225.43 mg/dL → Dữ liệu khá đối xứng.
- Độ lệch chuẩn (Standard Deviation): 43.51 → Cholesterol có độ phân tán khá rộng.

Dữ liệu dạng số (Numeric)

- Toàn bộ dữ liệu trong Cholesterol Level là kiểu float64.
- Không có giá trị NULL (tỷ lệ 0%).
- Không cần xử lý kiểu dữ liệu, hoàn toàn phù hợp để phân tích số.

Exercise Habits

Input Metadata		Exercise Habits (Field Data Types)	Count	Percentage
Field Name	Exercise Habits	VARCHAR	10000	100,00%
Field Data Type	VARCHAR	Exercise Habits (Top 5 Values)		Count
Field Length	10	High	3397	33,97%
Data Profiling Summary Statistics		Medium	3332	33,32%
NULL	0	Low	3271	32,71%
Missing	0			
Actual	10000			
Completeness	100,00%			
Cardinality	3			
Uniqueness	0,03%			
Distinctness	0,03%			
Data Profiling Additional Statistics				
Field Data Type	1			
Field Length (MIN)	3			
Field Length (MAX)	6			
Field Formats	1			

Tổng quát:

- Completeness cao (100%) không có giá trị NULL nào
- Cardinality có giá trị là 3, nghĩa là chỉ mang 5 giá trị duy nhất, gồm các mức độ khác nhau
- Uniqueness: 0.03% → Các mức tập luyện lặp lại nhiều trong tập dữ liệu.
- Distinctness: 0.03% → Dữ liệu có sự lặp lại cao giữa các nhóm tập luyện.

Nhận xét:

- Số người có thói quen tập thể dục ở 3 mức tương đối gần bằng nhau, trong đó mức “High” chiếm nhiều nhất.

Smoking

Input Metadata		Smoking (Field Data Types)	Count	Percentage
Field Name	Smoking	VARCHAR	10000	100,00%
Field Data Type	VARCHAR	Smoking (Top 2 Values)	Count	Percentage
Field Length	3	Yes	5148	51,48%
Data Profiling Summary Statistics		No	4852	48,52%
NULL	0			
Missing	0			
Actual	10000			
Completeness	100,00%			
Cardinality	2			
Uniqueness	0,02%			
Distinctness	0,02%			
Data Profiling Additional Statistics				
Field Data Type	1			
Field Length (MIN)	2			
Field Length (MAX)	3			
Field Formats	1			

Tổng quát:

- Completeness cao (100%) không có giá trị NULL nào
- Cardinality có 2 giá trị duy nhất “Yes” và “No” cho thấy dữ liệu được nhóm gọn.
- Uniqueness: 0.02% → Vì chỉ có hai giá trị nên mức độ duy nhất thấp
- Distinctness: 0.02% → Các giá trị “Yes” và “No” xuất hiện nhiều lần.

Nhận xét:

- Với những người mắc bệnh tim thì đa số là những người có hút thuốc (51,48% trên 10000 người được khảo sát).

Family Heart Disease

Input Metadata		Family Heart Disease (Field Data Types)	Count	Percentage
Field Name	Family Heart Disease	VARCHAR	10000	100,00%
Field Data Type	VARCHAR	Family Heart Disease (Top 2 Values)	Count	Percentage
Field Length	3	No	5025	50,25%
Data Profiling Summary Statistics		Yes	4975	49,75%
NULL	0			
Missing	0			
Actual	10000			
Completeness	100,00%			
Cardinality	2			
Uniqueness	0,02%			
Distinctness	0,02%			
Data Profiling Additional Statistics				
Field Data Type	1			
Field Length (MIN)	2			
Field Length (MAX)	3			
Field Formats	1			

Tổng quát:

- Completeness cao (100%) không có giá trị NULL nào
- Cardinality có 2 giá trị duy nhất “Yes” và “No” cho thấy dữ liệu được nhóm gọn.

- Uniqueness: 0.02% → Vì chỉ có hai giá trị nên mức độ duy nhất thấp
- Distinctness: 0.02% → Các giá trị “Yes” và “No” xuất hiện nhiều lần.

Nhận xét:

- Nhận thấy yếu tố duy truyền cũng chiếm một phần trong số những người có bệnh tim -> nếu gia đình có tiền sử bệnh tim, nguy cơ mắc bệnh tim sẽ khá cao.

BMI

Input Metadata		BMI (Field Data Types)	Count	Percentage
Field Name	BMI	Float	10000	100,00%
Field Data Type	Float	BMI (Top 5 Values)	Count	Percentage
Field Length	10	29,0772689275110	22	0,22%
Data Profiling Summary Statistics		24,9915910916903	1	0,01%
NULL	0	25,2217985244363	1	0,01%
Missing	0	29,8554471423716	1	0,01%
Actual	10000	24,1304768828524	1	0,01%
Completeness	100,00%	BMI (Field Formats)	Count	Percentage
Cardinality	9979	XX,XXXXXXXXXXXXXXXX	10000	100,00%
Uniqueness	99,79%			
Distinctness	99,79%			
Data Profiling Additional Statistics				
Field Data Type	1			
Field Value (MIN)	18,0028369436750			
Field Value (MAX)	39,9969537965812			
Field Formats	1			

Tổng quát:

- Completeness cao (100%) không có giá trị NULL nào
- Cardinality có 9979 giá trị duy nhất, cho thấy sự đa dạng trong chỉ số khối cơ thể.
- Uniqueness: 99.79% → Có nhiều mức BMI khác nhau, nhưng vẫn có sự trùng lặp
- Distinctness: 99.79% → Đa dạng dữ liệu nhưng vẫn có vài giá trị xuất hiện nhiều lần.

Nhận xét:

- Ở ngưỡng BMI > 29, gần mức béo phì sẽ chiếm đa số trong số những người mắc bệnh tim -> việc thừa cân béo phì cũng là một trong những nguyên nhân dẫn đến bệnh tim

Alcohol Consumption:

Metadata						Alcohol Consumption - Popular		
Attribute	Value					Value	Count	Percentage(%)
Field Name	Alcohol Consumption					Non	2586	25.86
Field Datatype	object					Medium	2500	25
Field Length	1					Low	2488	24.88
						High	2426	24.26
Data Profiling Summary								
Attribute	Value							
NULL	0					Alcohol Consumption - Field Formats		
Missing	0					Format	Count	Percentage(%)
Actual	10000					XXX	5074	50.74
Completeness (%)	100					XXXXXX	2500	25
Cardinality	4					XXXX	2426	24.26
Uniqueness (%)	0.04					Alcohol Consumption - Field Data Types		
Distinctness (%)	0.04					Data Type	Count	Percentage(%)
Data Profiling Additional Statistics						object	10000	100
Attribute	Value							
Data Types	1							
Field Length (MIN)	3							
Field Length (MAX)	6							
Field Value (MAX)	N/A							
Field Formats	3							

Tổng quát:

- Độ hoàn chỉnh (Completeness) đạt 100%, dữ liệu về Alcohol Consumption bị thiếu khá nhiều với 2586 giá trị Non (chiếm 25.86%), chỉ có 74.14% dữ liệu là hợp lệ.
- Cardinality (Số lượng giá trị duy nhất) chỉ có 4, tức là chỉ có 3 mức tiêu thụ rượu (“Non”, “Low”, “Medium”, “High”).
- Uniqueness và Distinctness rất thấp (0.04%), điều này có nghĩa là dữ liệu bị trùng lặp nhiều và chỉ có 4 nhóm phân loại.

Nhận xét chi tiết:

- Cả 4 mức tiêu thụ “Non”, “Low”, “Medium và “High” có tỉ lệ tương đương nhau (~25.86%-25%-24.88%-24.26%), nghĩa là mức tiêu thụ rượu của đối tượng nghiên cứu được chia khá đồng đều giữa 4 mức.
- Số lượng người không hút thuốc chiếm số lượng lớn nhất với 25.86%.
- Số lượng người hút thuốc với cường độ cao chiếm số lượng ít nhất với 24.26%
- Độ dài dữ liệu (Field Length) dao động từ 3 đến 6 ký tự, cho thấy dữ liệu được chuẩn hóa và không có giá trị bất thường về độ dài.
- Dữ liệu ở dạng object.

Stress Level

Metadata						Stress Level - Popular		
Attribute	Value					Value	Count	Percentage(%)
Field Name	Stress Level					Medium	3387	33.87
Field Datatype	object					Low	3320	33.2
Field Length	1					High	3271	32.71
						Non	22	0.22
Data Profiling Summary								
Attribute	Value					Stress Level - Field Formats		
NULL	0					Format	Count	Percentage(%)
Missing	0					XXXXXX	3387	33.87
Actual	10000					XXX	3342	33.42
Completeness (%)	100					XXXX	3271	32.71
Cardinality	4							
Uniqueness (%)	0.04					Stress Level - Field Data Types		
Distinctness (%)	0.04					Data Type	Count	Percentage(%)
						object	10000	100
Data Profiling Additional Statistics								
Attribute	Value							
Data Types	1							
Field Length (MIN)	3							
Field Length (MAX)	6							
Field Value (MAX)	N/A							
Field Formats	3							

Tổng quát:

- Độ Completeness rất cao (99.78%), chỉ có 22 giá trị Non (0.22%), cho thấy dữ liệu gần như đầy đủ..
- Cardinality (Số lượng giá trị duy nhất) chỉ có 4, tức là chỉ có 4 mức tiêu thụ rượu (“Non”, ”Low”, “Medium”, “High”).
- Uniqueness và Distinctness rất thấp (0.04%), điều này có nghĩa là dữ liệu bị trùng lặp nhiều và chỉ có 4 nhóm phân loại.

Nhận xét chi tiết:

- Cả 3 mức “Low” (33.2%), “Medium” (33.87%) và “High” (32.71%) có tỷ lệ khá cân bằng, cho thấy mức độ stress trong dữ liệu phân bố tương đối đều.
- Số lượng Non rất ít (22 trường hợp - 0.22%), nên có thể dễ dàng xử lý mà không ảnh hưởng đáng kể đến phân tích.
- Độ dài dữ liệu (Field Length) dao động từ 3 đến 6 ký tự, đảm bảo dữ liệu được chuẩn hóa và không có giá trị bất thường.
- Dữ liệu ở dạng object.

Heart Disease Status

Metadata		Heart Disease Status - Popular		
Attribute	Value	Value	Count	Percentage(%)
Field Name	Heart Disease Status	No	8000	80
Field Datatype	object	Yes	2000	20
Field Length	1			
		Heart Disease Status - Field Data Types		
Data Profiling Summary		Data Type	Count	Percentage(%)
Attribute	Value	object	10000	100
NULL	0			
Missing	0			
Actual	10000			
Completeness (%)	100			
Cardinality	2			
Uniqueness (%)	0.02			
Distinctness (%)	0.02			
Data Profiling Additional Statistics				
Attribute	Value			
Data Types	1			
Field Length (MIN)	2			
Field Length (MAX)	3			
Field Value (MAX)	N/A			
Field Formats	2			

Tổng quát:

- Dữ liệu hoàn chỉnh 100%, không có giá trị NULL hoặc bị thiếu.
- Chỉ có 2 giá trị phân loại (Yes/No), thể hiện tình trạng mắc bệnh tim.
- Uniqueness và Distinctness rất thấp (0.02%), cho thấy dữ liệu mang tính phân loại nhị phân với tỷ lệ xuất hiện lặp lại cao.

Nhận xét chi tiết:

- 80% dữ liệu có giá trị "No" (không mắc bệnh tim), trong khi chỉ 20% có giá trị "Yes" (mắc bệnh tim).
 - + Điều này cho thấy số lượng người không mắc bệnh tim chiếm phần lớn trong tập dữ liệu.
 - + Dữ liệu bị mất cân bằng (imbalance), có thể ảnh hưởng đến các mô hình dự đoán nếu áp dụng machine learning
- Độ dài dữ liệu từ 2 đến 3 ký tự, phù hợp với giá trị "Yes" hoặc "No", không có dấu hiệu dữ liệu không hợp lệ.

2. Abstraction

2.1. Domain task 1: Thể hiện doanh thu trên các dòng sản phẩm giữa các tháng

2.1.1. Data abstraction

Data:	patient_heart_disease						
Item:	1 dòng là 1 bệnh nhân						
Dataset availability:	Static						
	Semantics	Attribute Type	Hierarchical	Characteristic	Direction	Quantitative Type	Bin Number
Age	Tuổi bệnh nhân	Quantitative	None	Continuous	Squential	Ratio	8
Heart Disease	Trạng thái bệnh	Categorical	None	Discrete	None	None	0

2.1.2. Task abstraction

Produce à Explore à Sum

- **Produce**
 - o Chia cột Age thành nhóm tuổi (20-29, 30-39,..., > 80)
 - o Kiểm tra dữ liệu thiếu và làm sạch nếu cần
- **Explore**
 - o Đếm số ca mắc bệnh tim theo từng nhóm tuổi
 - o Vẽ biểu đồ cột để quan sát xu hướng.
- **Sum**
 - o **Nhận xét:** tuổi cao tỉ lệ thuận với bệnh tim tăng
 - o **Nhóm tuổi nguy cơ cao:** Nhóm trên 50 tuổi nguy cơ cao nhất

2.2. Domain task 2: **Mối quan hệ giữa giới tính và bệnh tim**

2.2.1. Data abstraction

Data:	gender_heart_disease						
Item:	1 dòng là 1 bệnh nhân						
Dataset availability:	Static						
	Semantics	Attribute Type	Hierarchical	Characteristic	Direction	Quantitative Type	Bin Number
Gender	Giới tính	Categorical	None	Discrete	None	None	0
Heart Disease	Trạng thái bệnh	Categorical	None	Discrete	None	None	0

2.2.2. Task abstraction

Produce à Explore à Sum

- **Produce**
 - o Kiểm tra cột Gender có bị lỗi định dạng không (“M”, “F” hay “Female”, “Male”)
 - o Kiểm tra dữ liệu thiếu và làm sạch nếu cần.
- **Explore**
 - o Đếm số bệnh nhân nam và nữ mắc bệnh tim
 - o Tính tỷ lệ phần trăm mắc bệnh theo giới tính
 - o Vẽ biểu đồ cột hoặc biểu đồ tròn

- **Sum**

- **Nhận xét:** tỷ lệ mắc bệnh tim ở nam cao hơn nữ, có thể do yếu tố sinh lý hoặc thói quen sống.

2.3. Domain task 3: **Mối quan hệ giữa tình trạng hút thuốc và bệnh tim**

2.3.1. Data abstraction

Attr	Abstraction									
Data type	Attribute and Item									
Dataset type	Table									
Dataset availability	Static									
No	Attribute Name	Attribute Type (C,O,Q)	Direction	Hierarchical	Characteristic	Direction2	Quantitative	Bin Number	Semantic	
1	Smoking	Categorical	None	No	Discrete	None	None	3	Yes. 'Có hút thuốc' hoặc 'Không hút thuốc'	
2	Heart Disease Status	Categorical	None	No	Discrete	None	None	2	Yes. 'Có bị bệnh tim' hoặc 'Không bị bệnh tim'	

2.3.2. Task abstraction

Phân tích **Analyze** → **Search** → **Query**

Analyze:

-**Consume:** Dữ liệu về tình trạng hút thuốc và bệnh tim đã có sẵn.

-**Biểu diễn:** Có thể dùng bảng thống kê hoặc biểu đồ tỷ lệ → **Present**

Search:

-Không cần tìm kiếm một cá nhân cụ thể mà muốn quan sát toàn bộ xu hướng chung.

-Không phù hợp với **Lookup** hay **Locate** do domain task không có nhắm đến 1 sản phẩm cụ thể mà cần tìm mối quan hệ giữa các thuộc tính → **Explore**

Query:

-Tìm được mối quan hệ giữa các thuộc tính và tổng hợp tỷ lệ bệnh tim theo từng nhóm hút thuốc → **Summarize**

=> **Present** → **Explore** → **Summarize**

2.4. Domain task 4: **Mối quan hệ giữa tình trạng hút thuốc và bệnh tim**

2.4.1. Data abstraction

No	Attribute Name	Attribute Type (C,O,Q)	Direction	Hierarchical	Characteristic	Direction2	Quantitative	Bin Number	Semantic	
1	Exercise Habits	Ordinal	None	No	Discrete	None	None	3	Yes. 'Mức độ tập thể dục đo được'	
2	Heart Disease Status	Categorical	None	No	Discrete	None	None	2	Yes. 'Có bị bệnh tim' hoặc 'Không bị bệnh tim'	

2.4.2. Task abstraction

Phân tích theo **Analyze** → **Search** → **Query**

Analyze:

Consume: Dữ liệu về tần suất tập thể dục và tình trạng bệnh tim đã có sẵn, có thể biểu diễn trực tiếp → **Present**

Search:

Vì cần tìm hiểu mối quan hệ giữa tần suất tập thể dục và bệnh tim trong **toàn bộ dữ liệu**, không chỉ một điểm dữ liệu cụ thể → **Explore**

Query:

Yêu cầu phân tích dữ liệu và tổng hợp xu hướng giữa hai biến →

Summarize

=> **Present** → **Explore** → **Summarize**

2.5. Domain task 5: Mức cholesterol thay đổi như thế nào giữa những người có và không có bệnh tim?

2.5.1. Data abstraction

Attr		Abstraction							
Data type		Attribute and Item							
Dataset type		Table							
Dataset availability		Static							
No	Attribute Name	Type (C, O, Q)	Interval/Ratio	Key/Value	Direction	Hierarchical	Continuous/Discrete	Semantic	
1	Cholesterol Level	Quantitative	Ratio	Value	Sequential	No	Continuous	Yes. Đây là mức Cholesterol đo được từ bệnh nhân.	
2	Heart Disease Status	Categorical	None	Key	None	No	Discrete	Yes. 'Có bệnh tim' hoặc 'Không có bệnh tim'	

2.5.2. Task abstraction

Analyze:

- **Consume:** Dữ liệu về mức cholesterol và tình trạng bệnh tim đã có sẵn, có thể biểu diễn trực tiếp. → **Present**

Search:

- Domain task không nhắm đến một cá nhân cụ thể → Không có target cụ thể → Không thể là **Lookup** hay **Locate**.

- Domain task yêu cầu phân tích sự khác biệt mức cholesterol giữa các nhóm bệnh tim → **Explore**

Query:

- Domain task yêu cầu phân tích mức cholesterol giữa hai nhóm (có bệnh tim và không có bệnh tim) → Có sự so sánh → **Compare**

=> **Present** → **Explore** → **Compare**

2.6. Domain task 6: Có mối tương quan nào giữa chỉ số BMI và bệnh tim không?

2.6.1. Data abstraction

No	Attribute Name	Type (C, O, Q)	Interval/Ratio	Key/Value	Direction	Hierarchical	Continuous/Discrete	Semantic
1	BMI	Quantitative	Ratio	Value	Sequential	No	Continuous	Yes. Đây là chỉ số khối cơ thể của bệnh nhân.
2	Heart Disease Status	Categorical	None	Key	Sequential	Yes	Discrete	Yes. 'Có bệnh tim' hoặc 'Không có bệnh tim'

2.6.2. Task abstraction

Analyze:

- Consume:** Dữ liệu về chỉ số BMI và tình trạng bệnh tim đã có sẵn, có thể biểu diễn trực tiếp.
→ **Present**

Search:

- Domain task không nhắm đến một cá nhân cụ thể → Không có target cụ thể → Không thể là **Lookup** hay **Locate**.
- Domain task yêu cầu tìm mối quan hệ giữa BMI và bệnh tim → **Explore**

Query:

- Domain task yêu cầu tìm ra mối tương quan giữa hai thuộc tính trong toàn bộ dữ liệu → **Summarize**

=> Present → Explore → Summarize

2.7. Domain task 7: Tiểu sử gia đình mắc bệnh tim có làm tăng nguy cơ không ?

2.7.1. Data abstraction

Attr	Abstraction								
Data type	Attribute and Item								
Dataset type	Table								
Dataset availability	Static								
No	Attribute Name	Type(C,O,Q)	Interval/Ratio	Key/Value	Direction	Hierarchical	Continuous/Discrete	Semantic	
1	Family Heart Disease	Categorical	None	Key	None	None	Discrete	Yes. Đây là "có tiểu sử bệnh tim" hoặc "không có tiểu sử bệnh tim"	
2	Heart Disease Status	Categorical	None	Value	None	None	Discrete	Yes. Đây là "có bệnh tim" hoặc "không có bệnh tim"	

2.7.2. Data abstraction

Analyze:

- **Consume:** Dữ liệu về tiểu sử gia đình mắc bệnh tim và tình trạng bệnh tim đã có sẵn, có thể biểu diễn trực tiếp.

→ **Present**

Search:

- Domain task không nhắm đến một cá nhân cụ thể → Không có target cụ thể → Không thể là **Lookup** hay **Locate**.
- Domain task yêu cầu tìm mối quan hệ giữa tiểu sử gia đình mắc bệnh tim và tình trạng bệnh tim → **Explore**

Query:

- Domain task yêu cầu tìm ra mối tương quan giữa hai thuộc tính trong toàn bộ dữ liệu → **Summarize**

=> Present → Explore → Summarize

2.8. Domain task 8: Sự phân bố nồng độ Cholesterol khác nhau như thế nào giữa nam và nữ ?

2.8.1. Data abstraction

Attr	Abstraction							
Data type	Attribute and Item							
Dataset type	Table							
Dataset availability	Static							
No	Attribute Name	Type(C,O,Q)	Interval/Ratio	Key/Value	Direction	Hierarchical	Continuous/Discrete	Semantic
1	Cholesterol Level	Quantitative	Ratio	Value	None	None	Continuous	Yes. Đây là nồng độ Cholesterol có trong máu
2	Gender	Categorical	None	Key	None	None	Discrete	Yes. Đây là giới tính của bạn nhân nam hoặc nữ

2.8.2. Task abstraction

Analyze:

- **Consume:** Dữ liệu về mức độ Cholesterol và giới tính đã có sẵn, có thể biểu diễn trực tiếp.

→ **Present**

Search:

- Domain task yêu cầu sự so sánh sự phân bố Cholesterol giữa 2 nhóm giới tính → Không có target cụ thể → Không thể là **Lookup** hay **Locate**.
- Domain task yêu cầu tìm sự phân bố giữa Cholesterol theo từng giới tính → **Explore**

Query:

- Domain task yêu cầu tìm ra sự phân bố giữa hai thuộc tính trong toàn bộ dữ liệu →

Summarize

=> **Present** → **Explore** → **Summarize**


3. Thiết kế idiom (đang thực hiện)

3.1. Domain task 1

3.1.1. Idiom

Idiom	Line charts	
Data	PRODUCTLINE: C	
	ORDERDATE: O	
	SALES: Q	
Encode	Mark: line	
	Channel	O: pos ngang
		Q: pos dọc
		C: color
TASK	So sánh giữa các đường là các dòng sản phẩm	
SCALE	Keys: 7 Level:	

3.1.2. Biểu đồ



3.1.3. Đánh giá

- **Tính biểu đạt**
 - Biểu diễn tất cả item có trong dataset
 - Sử dụng kênh vị trí thuộc tính ORDERDATE và SALES và màu sắc cho PRODUCTLINE phù hợp với bảng ranking channel.
- **Tính hiệu quả**
 - Accuracy: độ lỗi log_error < 1.5
 - Discriminability: phân biệt được mỗi item thông qua từng line trên biểu đồ
 - Separability: không xét vì không có thuộc tính nào sử dụng 2 channel để biểu diễn
- **Phân tích biểu đồ**

- Quan sát biểu đồ ta có thể thấy tháng 11 là tháng mà doanh thu của tất cả các dòng xe tăng vọt

3.2. Domain task 2

3.3. Domain task 3